ΠΑΝΕΠΙΣΤΗΜΙΟ ΔΥΤΙΚΗΣ ΑΤΤΙΚΗΣ

UNIVERSITY OF WEST ATTICA

Σχολή Μηχανικών

Τμήμα Μηχανικών Πληροφορικής και Υπολογιστών

Ανάκτηση Πληροφορίας

Δημιουργία μηχανής αναζήτησης

ΕΥΦΡΟΣΥΝΗ ΒΑΡΣΟΥ 21390021

ΑΓΓΕΛΟΣ ΚΩΝΣΤΑΝΤΙΝΟΣ ΜΕΝΤΖΕΛΟΣ 21390132

Github Project Link

Βήμα 1. Συλλογή δεδομένων

Περιγραφή συνόλου δεδομένων

Το σύνολο δεδομένων είναι επιλεγμένα άρθρα που επιλέξαμε από το Wikipedia. Μερικά από αυτά επικεντρώνονται σε θεματολογίες που αφορούν την επιστήμη, την τεχνολογία και άλλα σχετικά πεδία. Άλλα άρθρα επικεντρώνονται σε άλλα τελείως διαφορετικά θέματα όπως την τέχνη, ιστορία κτλ. Επιλέξαμε άρθρα με παρόμοια θεματολογία σχετικά με την επιστήμη για να δούμε αν με πολλές ομοιότητες (π.χ. λεξιλόγιο) η μηχανή αναζήτησης δίνει αποδοτικά αποτελέσματα. Ωστόσο, επιλέξαμε και άρθρα που δεν έχουν κάποια διακριτή συσχέτισή για να δούμε και αν η μηχανή αναζήτησης σε τελείως διαφορετικά θέματα βρει και εκεί κάποιες ομοιότητες που δεν περιμέναμε. Γενικά, επιλέξαμε μια ποικιλία από άρθρα για να μπορούμε να εξετάσουμε αποτελεσματικά την μηχανή αναζήτησης σε σχέση με το ερώτημα του χρήστη.

Περιγραφή της μεθοδολογίας συλλογής

Για την συλλογή των δεδομένων, υλοποιήσαμε έναν web crawler με BeautifulSoup. Ειδικότερα, δημιουργήσαμε μια λίστα από άρθρα από την Wikipedia και για κάθε URL που αντιστοιχεί σε κάθε από αυτά καλούμε την συνάρτηση crawl_wikipedia(). Η συνάρτηση αυτή τώρα, είναι υπεύθυνη για την εξαγωγή δεδομένων (τίτλου και περιεχομένου) από την κάθε HTML σελίδα. Ειδικότερα, στέλνει ένα HTTP request στην διεύθυνση URL και με την βοήθεια της βιβλιοθήκης BeautifulSoup βρίσκει το h1 tag που αντιστοιχεί στον τίτλο του άρθρου καθώς και όλα τα p tags που αντιστοιχούν στο περιεχόμενο του άρθρου. Με αυτόν τον τρόπο, δημιουργήσαμε μια δομή dictionary που κάθε τίτλος άρθρου αντιστοιχεί σε κάποιο περιεχόμενο και έτσι το αποθηκεύουμε σε ένα .json και .csv (wiki_data) με αυτήν την μορφή.

Βήμα 2. Προεπεξεργασία κειμένου (Text Processing)

Για την προεπεξεργασία κειμένου, ακολουθήσαμε μια σειρά από ενέργειες για να «καθαρίσουμε» τα δεδομένα. Τα άρθρα του Wikipedia όπως γνωρίζουμε είναι γεμάτο από πηγές στο κείμενο τους που συμβολίζονται με δύο αγκύλες και ανάμεσα τους έναν αριθμό που αντιστοιχεί σε μια παραπομπή στο τέλος του άρθρου ή σε link άλλου άρθρου (π.χ. [1]). Οι πηγές όμως δεν μας ενδιαφέρουν για την μηχανή αναζήτησης καθώς δεν παρέχουν κάποια πληροφορία στο περιεχόμενο. Για αυτόν τον λόγο και τις αφαιρούμε με το αντίστοιχο regex. Στην συνέχεια, αφαιρούμε και τα σημεία στίξης καθώς για τον ίδιο λόγο δεν προσφέρουν κάποια πληροφορία στην μηχανή αναζήτησης.

Ως κύρια τεχνική προεπεξεργασίας επιλέξαμε tokenization με stemming. Δηλαδή, για κάθε άρθρο χωρίσαμε ανά λέξη το κείμενό τους (token) και με την χρήση stemming κρατάμε μόνο την ρίζα της λέξης (π.χ. running → run). Με αυτόν τον τρόπο, όλες οι ομόρριζες λέξεις ομαδοποιούνται στην μία ρίζα καθιστώντας το νόημα του κειμένου πιο συγκεκριμένο/ειδικό. Αυτό καθιστά το κείμενο και συνεπώς το σύνολο δεδομένων λιγότερο πολύπλοκο και βοηθάει την αποδοτικότητα της μηχανής αναζήτησης.

Ο κύριος λόγος που επιλέξαμε την τεχνική stemming αντί της lemmatization είναι η ταχύτητα και λιγότερης πολυπλοκότητας. Το stemming κυρίως χρησιμοποιείται σε μηχανές αναζητήσεις καθώς αν και έχουν πιο απλούς ευριστικούς (heuristic) κανόνες και δεν έχουν τόση ακρίβεια, είναι άκρως πιο αποδοτικοί σε μεγάλα dataset από ότι το lemmatization που σε σύγκριση είναι αργό. Το lemmatization κυρίως χρησιμοποιείται για περισσότερη ακρίβεια στην ανάλυση του κειμένου και όταν θέλουμε να κρατήσουμε την συνοχή του κειμένου για ειδικότερη ανάλυση των εννοιών του κειμένου (π.χ. σε ιατρικά άρθρα όταν το νόημα του κείμενου έχει μεγαλύτερη σημασία). Τέλος, αφαιρέσαμε και όλα τα stop words δηλαδή σύντομες μικρές συχνές λέξεις που συνήθως χρησιμοποιούνται λόγω γραμματικής (π.χ. the, and, but κτλ.). Αυτές οι λέξεις γενικά δεν προσφέρουν κάποιο περιεχόμενο στο νόημα του κειμένου και επιπλέον είναι σε αρκετά μεγάλη

συχνότητα. Επομένως, η αφαίρεσή τους καθιστά ακόμα πιο αποτελεσματική την αποδοτικότητα της μηχανής αναζήτησης.

Βήμα 3. Ευρετήριο (Indexing)

Εφόσον, καθαρίσαμε τα δεδομένα τώρα μέσω του stemming έχοντας πλέον πολλές ρίζες βασικών λέξεων μπορούμε να φτιάξουμε το αντεστραμμένο ευρετήριο (inverted index). Το inverted index είναι ένας πίνακας που αντιστοιχίζει λέξεις σε λίστες εγγράφων στα οποία εμφανίζονται αυτές οι λέξεις. Δηλαδή, στις στήλες αντιστοιχούν όλες οι συνολικά μοναδικές λέξεις από όλα τα άρθρα και κάθε γραμμή αποτελείται από το σύνολο των άρθρων με τιμή το πλήθος της κάθε λέξης. Η δομή δεδομένων που διατηρούμε το inverted index είναι ένα dictionary που αποτελείται από άλλα dictionaries. Το εξωτερικό dictionary αντιστοιχίζει τους τίτλους σε dictionaries των λέξεων και αυτά έχουν τιμή το πλήθος των tokens. Συνεπώς, με το ευρετήριο θα μπορέσουμε στην συνέχεια να υλοποιήσουμε την μηχανή αναζήτης καθώς καθιστά την ανάκτηση της πληροφορίας του dataset σημαντικά πιο γρήγορη.

Βήμα 4. Μηχανή αναζήτησης (Search Engine)

Επεξεργασία ερωτήματος (Query Processing)

Πλέον, έχοντας δημιουργήσει το αντεστραμμένο ευρετήριο από το προηγούμενο βήμα μπορούμε να βρούμε για κάποιο δόθεν query από τον χρήστη σε ποιο άρθρο ανήκει. Ειδικότερα, ο χρήστης πληκτρολογεί ένα query με χρήστη Boolean τελεστών (AND, OR, NOT) για παράδειγμα ‘term1 AND term2’ τα οποία γίνονται tokens για κάθε λέξη και operator που χρησιμοποιείται. Συνεπώς, διασχίζοντας όλα τα tokens (περιλαμβανόμενων και τον τελεστών) όποιο είναι λέξη βρίσκουμε τα άρθρα στο οποίο ανήκει ενώ αν είναι τελεστής κάνουμε την αντίστοιχή Boolean πράξη με τα αντίστοιχα άρθρα των κάθε term. Με αυτόν τον τρόπο, όταν χρησιμοποιούμε τον τελεστή AND επιστρέφουμε τα άρθρα που περιέχουν και τις δύο λέξεις, όταν χρησιμοποιούμε τον τελεστή OR επιστρέφουμε τα άρθρα που περιέχουν τουλάχιστον μία από τις δύο λέξεις και όταν χρησιμοποιούμε τον τελεστή NOT όλα τα άρθρα που περιέχουν την δοσμένη λέξη.

Κατάταξη αποτελεσμάτων (Ranking)

Για την κατάταξη των αποτελεσμάτων χρησιμοποιήσαμε 3 αλγόριθμους ανάκτησης τον TF-IDF, Vector Space Model και τον Okapi BM25. Υλοποιήσαμε μια απλή διεπαφή χρήστη στη γραμμή εντολών όπου ο χρήστης αρχικά διαλέγει τον αλγόριθμο που θέλει να χρησιμοποιήσει και στην συνέχεια πληκτρολογεί το query και επιστρέφονται σε ταξινομημένη σειρά τα best matched articles ανάλογα με το score που έχει υπολογίσει ο κάθε αλγόριθμος. Ο αλγόριθμος TF-IDF υλοποιεί την αναζήτηση υπολογίζοντας την συχνότητα εμφάνισης της σε ένα άρθρο (TF) και αντίστοιχα την σπάνια εμφάνιση της λέξης στο σύνολο των άρθρων (IDF) και συνδυάζοντας αυτές τις δύο τιμές βρίσκει την σημασία της δοσμένης λέξης για το σύνολο των δεδομένων. Ο αλγόριθμος Vector Space Model (VSM) λειτουργεί με παρόμοιο τρόπο με τον TF-IDF υπολογίζοντας τα score με τον ίδιο τρόπο αλλά με διαφορά ότι αναπαριστά τα άρθρα σε μορφή διανύσματος. Στην συνέχεια, με βάση το κάθε διάνυσμα που αναπαριστά ένα άρθρο ο αλγόριθμος τα συγκρίνει υπολογίζοντας το cosine similarity μεταξύ τους. Ο BM25 αντίστοιχα υλοποιεί την αναζήτηση υπολογίζοντας την πιθανότητα ύπαρξης μιας λέξης στο άρθρο ενσωματώνοντας και αυτός το TF, IDF στον τύπο υπολογισμού.

Βήμα 5. Αξιολόγηση συστήματος

Για την αξιολόγηση του συστήματος χρησιμοποιήσαμε τις μετρικές Precision, Recall, F1-score και το MAP (Mean Average Precision). Το Precision υπολογίζει πόσο αξιόπιστες είναι οι θετικές προβλέψεις (true positives) του μοντέλου, δηλαδή με υψηλό precision οι περισσότερες προβλέψεις του αλγόριθμου ανάκτησης

είναι σωστές. Το Recall αντίστοιχα, υπολογίζει την ικανότητα του αλγόριθμου να αναγνωρίσει τα θετικά δείγματα. Το F1-score είναι ο αρμονικός μέσος όρος του precision και του recall και υπολογίζει την συνολική απόδοση του αλγόριθμου συνδυάζοντας και τις δύο μετρικές. Τέλος, το MAP υπολογίζει τον μέσο όρο των precision των άρθρων για κάθε αναζήτηση και τις αθροίζει για να βρει τον συνολικό μέσο όρο για όλες τις αναζητήσεις του χρήστη.

Στον κώδικα τώρα, για κάθε αλγόριθμο διατηρούμε σε ένα dictionary τις αναζητήσεις του χρήστη και για κάθε αναζήτηση ποια άρθρα επιστράφηκαν (tf_results, vsm_results, bm25_results). Με αυτόν τον τρόπο, όταν ο χρήστης κάνει αρκετές αναζητήσεις και στην συνέχεια επιλέξει την επιλογή της αξιολόγησης επιστρέφονται οι τιμές των μετρικών για κάθε αλγόριθμο (εφόσον έχουν υπάρξει αναζητήσεις σε αυτούς).

Τρέχοντας τους διάφορους αλγόριθμους για διαφορετικές αναζητήσεις βλέπουμε ότι ο TF-IDF σε πολλές αναζητήσεις δεν είναι τόσο αποδοτικός όσο το VSM ή ο BM25 καθώς δεν λαμβάνει υπόψιν την σύνδεση κάποιων λέξεων. Όταν η αναζήτηση περιλαμβάνει μία λέξη είναι πολύ καλύτερος και συμπίπτει με τα αποτελέσματα των άλλων αλγορίθμων. Ο VSM και ο BM25 συμπίπτουν στα περισσότερα αποτελέσματα που επιστρέφουν αλλά επειδή ο VSM χρησιμοποιεί διανύσματα σε μεγάλα σύνολα δεδομένων δεν είναι τόσο αξιόπιστος όσο το BM25. Συνεπώς, η απόδοση στην μηχανή αναζήτησης λαμβάνοντας υπόψιν και τις μετρικές είναι καλύτερη όταν χρησιμοποιούμε τον αλγόριθμο BM25

Ενδεικτικές Δοκιμές

- digital writing

```
----------Results TF-IDF----------
Query given: digital writing
Document: Data science, Score: 0.0448
Document: Computer science, Score: 0.0313
Document: History, Score: 0.0269
Document: Literature, Score: 0.0225
Document: Technology, Score: 0.0220
Document: Deep learning, Score: 0.0198
Document: Internet, Score: 0.0178
Document: Music, Score: 0.0172
Document: Artificial intelligence, Score: 0.0163
Document: Programming language, Score: 0.0139
Document: Computer network, Score: 0.0138
Document: Operating system, Score: 0.0129
Document: Engineering, Score: 0.0126
Document: Machine learning, Score: 0.0115
Document: Mathematics, Score: 0.0106
Document: Science, Score: 0.0102
```

```
----------Results BM25----------
Query given: digital writing
Document: Literature, Score: 0.1170
Document: Data science, Score: 0.1084
Document: History, Score: 0.1037
Document: Music, Score: 0.1030
Document: Internet, Score: 0.0987
Document: Computer science, Score: 0.0903
Document: Artificial intelligence, Score: 0.0807
Document: Technology, Score: 0.0714
Document: Deep learning, Score: 0.0647
Document: Computer network, Score: 0.0609
Document: Operating system, Score: 0.0593
Document: Programming language, Score: 0.0585
Document: Science, Score: 0.0483
Document: Engineering, Score: 0.0407
Document: Machine learning, Score: 0.0353
Document: Mathematics, Score: 0.0255
```

```
----------Results Vector Space Model--------
Query given: digital writing
Document: Literature, Score: 0.0953
Document: History, Score: 0.0334
Document: Data science, Score: 0.0327
Document: Computer network, Score: 0.0323
Document: Computer science, Score: 0.0278
Document: Operating system, Score: 0.0241
Document: Internet, Score: 0.0215
Document: Programming language, Score: 0.0213
Document: Technology, Score: 0.0124
Document: Music, Score: 0.0123
Document: Science, Score: 0.0117
Document: Artificial intelligence, Score: 0.0113
Document: Deep learning, Score: 0.0075
Document: Engineering, Score: 0.0058
Document: Machine learning, Score: 0.0042
Document: Mathematics, Score: 0.0018
```

- computer vision

```
----------Results TF-IDF----------
Query given: computer vision
Document: Computer science, Score: 0.0454
Document: Machine learning, Score: 0.0260
Document: Science, Score: 0.0257
Document: Artificial intelligence, Score: 0.0236
Document: Deep learning, Score: 0.0236
Document: Data science, Score: 0.0232
Document: Art, Score: 0.0225
Document: Software engineering, Score: 0.0081
Document: Programming language, Score: 0.0076
Document: Operating system, Score: 0.0071
Document: Computer network, Score: 0.0068
Document: Engineering, Score: 0.0062
Document: Literature, Score: 0.0058
Document: Mathematics, Score: 0.0058
Document: Technology, Score: 0.0057
Document: Internet, Score: 0.0046
Document: Music, Score: 0.0045
```

```
----------Results Vector Space Model--------
Query given: computer vision
Document: Computer science, Score: 0.3484
Document: Operating system, Score: 0.0633
Document: Software engineering, Score: 0.0609
Document: Machine learning, Score: 0.0572
Document: Deep learning, Score: 0.0565
Document: Computer network, Score: 0.0507
Document: Data science, Score: 0.0480
Document: Programming language, Score: 0.0437
Document: Artificial intelligence, Score: 0.0393
Document: Internet, Score: 0.0363
Document: Technology, Score: 0.0252
Document: Mathematics, Score: 0.0226
Document: Science, Score: 0.0202
Document: Engineering, Score: 0.0185
Document: Art, Score: 0.0088
Document: Music, Score: 0.0044
Document: Literature, Score: 0.0035
```

```
----------Results BM25----------
Query given: computer vision
Document: Deep learning, Score: 0.1161
Document: Machine learning, Score: 0.1128
Document: Computer science, Score: 0.1106
Document: Artificial intelligence, Score: 0.0991
Document: Science, Score: 0.0834
Document: Operating system, Score: 0.0650
Document: Software engineering, Score: 0.0649
Document: Computer network, Score: 0.0648
Document: Programming language, Score: 0.0643
Document: Data science, Score: 0.0639
Document: Internet, Score: 0.0634
Document: Mathematics, Score: 0.0623
Document: Art, Score: 0.0609
Document: Engineering, Score: 0.0607
Document: Technology, Score: 0.0605
Document: Music, Score: 0.0549
Document: Literature, Score: 0.0414
```

- machine learning

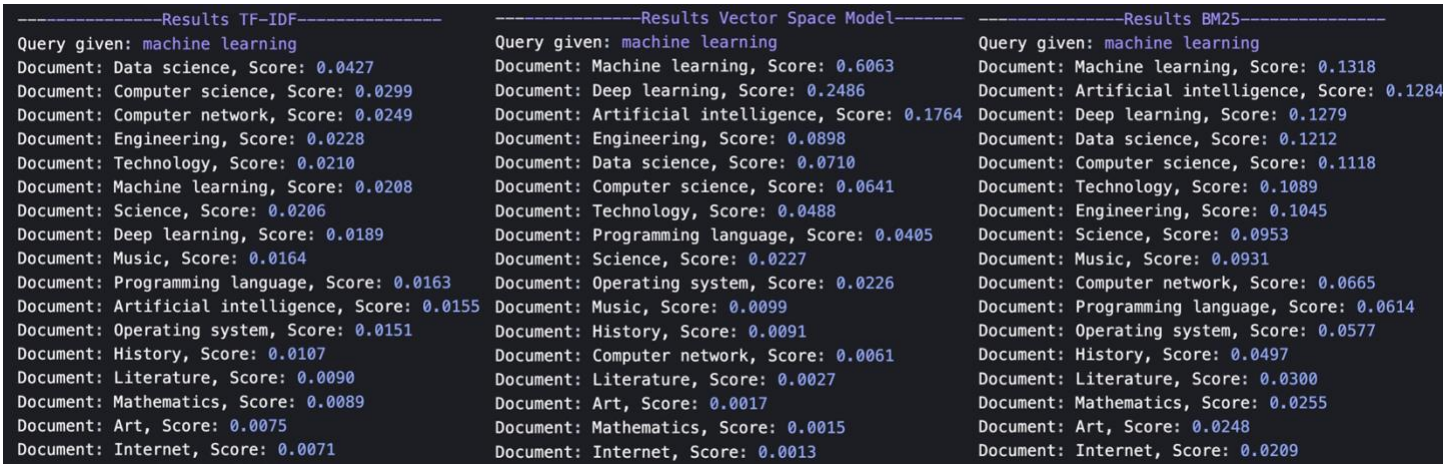

```
----------Results TF-IDF----------
Query given: machine learning
Document: Data science, Score: 0.0427
Document: Computer science, Score: 0.0299
Document: Computer network, Score: 0.0249
Document: Engineering, Score: 0.0228
Document: Technology, Score: 0.0210
Document: Machine learning, Score: 0.0208
Document: Science, Score: 0.0206
Document: Deep learning, Score: 0.0189
Document: Music, Score: 0.0164
Document: Programming language, Score: 0.0163
Document: Artificial intelligence, Score: 0.0155
Document: Operating system, Score: 0.0151
Document: History, Score: 0.0107
Document: Literature, Score: 0.0090
Document: Mathematics, Score: 0.0089
Document: Art, Score: 0.0075
Document: Internet, Score: 0.0071
```

```
----------Results Vector Space Model-------
Query given: machine learning
Document: Machine learning, Score: 0.6063
Document: Deep learning, Score: 0.2486
Document: Artificial intelligence, Score: 0.1764
Document: Engineering, Score: 0.0898
Document: Data science, Score: 0.0710
Document: Computer science, Score: 0.0641
Document: Technology, Score: 0.0488
Document: Programming language, Score: 0.0405
Document: Science, Score: 0.0227
Document: Operating system, Score: 0.0226
Document: Music, Score: 0.0099
Document: History, Score: 0.0091
Document: Computer network, Score: 0.0061
Document: Literature, Score: 0.0027
Document: Art, Score: 0.0017
Document: Mathematics, Score: 0.0015
Document: Internet, Score: 0.0013
```

```
----------Results BM25----------
Query given: machine learning
Document: Machine learning, Score: 0.1318
Document: Artificial intelligence, Score: 0.1284
Document: Deep learning, Score: 0.1279
Document: Data science, Score: 0.1212
Document: Computer science, Score: 0.1118
Document: Technology, Score: 0.1089
Document: Engineering, Score: 0.1045
Document: Science, Score: 0.0953
Document: Music, Score: 0.0931
Document: Computer network, Score: 0.0665
Document: Programming language, Score: 0.0614
Document: Operating system, Score: 0.0577
Document: History, Score: 0.0497
Document: Literature, Score: 0.0300
Document: Mathematics, Score: 0.0255
Document: Art, Score: 0.0248
Document: Internet, Score: 0.0209
```